

B I G D A T A

Unidad 3

Identificación de conceptos técnicos
de la analítica tradicional

IFCT0022 Big Data

3.1 La analítica tradicional

3.2 Estadística descriptiva

3.3 Álgebra lineal

3.4 Correlaciones

3.5 Contrastes de hipótesis

Índice de contenidos

3.1 La analítica tradicional

3.2 Introducción a la estadística descriptiva

3.3 Introducción al álgebra lineal

3.4 Correlaciones

3.5 Contrastes de hipótesis

3.1

¿Qué es la analítica tradicional?



COMENZAR

¿Qué es la analítica tradicional?

1

La "analítica tradicional" se refiere a los enfoques del análisis de datos que existían antes de la aparición del Big Data y la Inteligencia Artificial.

2

Se remonta a cuando los datos eran limitados en volumen y variedad. Usa técnicas estadísticas y matemáticas consolidadas para extraer conocimiento.

3

En la era del Big Data, es esencial entender cómo la analítica tradicional se adapta e integra en este nuevo contexto tecnológico.

Características principales



Recopilación y preparación

Datos estructurados en tablas. Limpieza y transformación antes del análisis.



Análisis descriptivo

Gráficos, tablas resumen y estadísticas para explorar el comportamiento de los datos.



Análisis inferencial

Pruebas de hipótesis, intervalos de confianza y regresión estadística.



Aplicaciones en decisiones

Negocios, economía, ciencias sociales, salud. Determina efectividad de estrategias.

Más características



Enfoque en datos históricos

Análisis de tendencias y patrones a lo largo del tiempo para entender el rendimiento pasado.



Herramientas convencionales

SPSS, SAS, R y Excel. Diseñadas para análisis estadístico y matemático.



Escalabilidad limitada

Dificultades con grandes volúmenes de datos no estructurados o semiestructurados propios de la era digital.

Analítica convencional vs. contemporánea

Aspecto	Analítica Convencional	Analítica Contemporánea
Escala de datos	Datos estructurados, menor volumen	Big Data: estructurados y no estructurados en tiempo real
Técnicas	Estadísticas descriptivas e inferenciales	ML, IA, NLP. Machine Learning, Inteligencia Artificial. Procesamiento de Lenguaje Natural.
Fuente de datos	Fuentes internas principalmente	Internas + redes sociales, sensores, IoT
Decisiones	Información retrospectiva	Información prospectiva y predictiva
Herramientas	SPSS, Excel	Python, R, Hadoop, Spark, TensorFlow
Velocidad	Más lento (menor volumen)	Más rápido: paralelización y procesamiento distribuido

3.2

Introducción a la estadística descriptiva



COMENZAR

¿Qué es la estadística?

La estadística es la ciencia que se ocupa de la recogida, clasificación, presentación e interpretación de la información numérica. Es el estudio de los datos que se obtienen de fenómenos repetibles.

¿Por qué la necesitamos?

Para saber por qué un proceso se comporta como lo hace.

Para reducir la variabilidad y mejorar la capacidad del proceso.

Para conocer la verdad sobre el mundo real.

Conceptos básicos de la estadística

POBLACIÓN

Conjunto total de objetos, personas o eventos a estudiar. Ej: todos los estudiantes matriculados en una universidad.

MUESTRA

Subconjunto representativo de la población. Los resultados obtenidos deben poder generalizarse a toda la población.

ELEMENTO

Unidad de análisis. Cualquier cosa que pueda ser identificada y estudiada en un contexto específico.

Conceptos básicos (continuación)

VARIABLE

Característica que se mide en cada elemento. Ej: estatura, edad o género de los estudiantes.

OBSERVACIÓN

Valor de una variable para un elemento concreto. Ej: el peso de cada estudiante en una escuela.

CASO

Conjunto de observaciones para un elemento. Ej: cada árbol individual en un estudio de crecimiento forestal.

Tipos de variables: cualitativas

Variables NO MÉTRICAS, CUALITATIVAS o CATEGÓRICAS: representan cualidades o características que no pueden ser medidas numéricamente.

NOMINALES

Representan categorías SIN orden específico.

Ejemplo: el color de un automóvil (rojo, azul, verde).

Ejemplo: categoria pelicula: ciencia ficcion, drama, comedia, terror

No existe una relación de magnitud entre las categorías.

ORDINALES

Representan categorías CON orden específico.

Ejemplo: clasificación de película (1-5 estrellas) o nivel educativo (primaria, secundaria, universidad).

Existe jerarquía, pero la distancia entre valores no es constante.

Tipos de variables: cuantitativas

Variables MÉTRICAS o CUANTITATIVAS: representan cantidades numéricas medibles con precisión.

VARIABLE DE INTERVALO

Escala numérica con distancias uniformes pero SIN punto cero absoluto.

Ejemplo: temperatura en °C o °F. La diferencia entre 10° y 20° es igual que entre 20° y 30°, pero 0° no significa ausencia de temperatura.

VARIABLE COCIENTE

Escala numérica con distancias uniformes y CON punto cero verdadero.

Ejemplo: peso en kg. Tiene un cero absoluto (ausencia total de peso). Permite afirmar que 40 kg es el doble de 20 kg.

Variables continuas vs. discretas



CONTINUAS

Pueden tomar CUALQUIER valor dentro de un rango determinado.

No hay saltos entre valores.

Ejemplos:

- Altura de una persona
- Temperatura del aire
- Tiempo en completar una tarea



DISCRETAS

Solo pueden tomar valores ENTEROS o específicos de una lista definida.

Existen saltos entre valores posibles.

Ejemplos:

- Número de hijos en una familia
- Número de estudiantes en clase
- Número de ventas diarias

Variables según su papel en el análisis

DEPENDIENTES

Son las variables que se estudian y se intentan explicar. Son el resultado o efecto que se quiere analizar.

INDEPENDIENTES

Las que están relacionadas o predicen la variación de la variable dependiente. Son la causa o factor que influye.

INTERVINIENTES O DE CONTROL

Las que ayudan a explicar o matizan la relación entre la variable independiente y la dependiente.

Ejemplo: El ejercicio físico (independiente) → reducción del estrés (dependiente) → controlado por la edad de los participantes (interveniente).

Tipos de estadística



DESCRIPTIVA

Usa métodos gráficos para interpretar los datos mejor. Describe, resume y organiza los datos para que sean fácilmente comprensibles.

Incluye medidas de tendencia central, dispersión, frecuencias y representaciones gráficas.



INFERENCIAL

Usa las matemáticas para modelar y predecir variaciones. Permite hacer inferencias sobre poblaciones basadas en muestras.

Incluye pruebas de hipótesis e intervalos de confianza.

La estadística descriptiva

La estadística descriptiva es una rama de la estadística que se enfoca en la descripción, el resumen y la presentación de los datos de una muestra o población.

- Medidas de tendencia central: media, mediana, moda.

- Medidas de forma: asimetría y curtosis.

- Frecuencias absolutas, relativas y porcentajes.

- Medidas de dispersión: rango, varianza y desviación típica.

- Representaciones gráficas: sectores, barras, histograma, dispersión.

- Medidas de asociación: correlación de Pearson, coeficiente de contingencia.

Categorías de la estadística descriptiva



UNIVARIADA

Análisis de una SOLA variable. Utiliza medidas de tendencia central, dispersión y gráficos sencillos.



BIVARIADA

Análisis de DOS variables y su relación. Usa correlación, regresión lineal simple, tablas de contingencia.



MULTIVARIANTE

Análisis de DOS O MÁS variables. Técnicas: análisis factorial, regresión múltiple, componentes principales.

Distribuciones univariantes

Las técnicas más comunes de descripción univariante incluyen:

Medidas de tendencia central (media, mediana, moda) · Medidas de dispersión (desviación estándar, rango, varianza) · Representaciones gráficas (histogramas, diagramas de barras, gráficos de sectores).

Tendencia Central

- Media (promedio)
- Mediana (valor central)
- Moda (valor más frecuente)

Dispersión

- Rango (max - min)
- Varianza (dispersión cuadrática)
- Desviación estándar ($\sqrt{\text{varianza}}$)

Representación gráfica

- Histograma (datos continuos)
- Diagrama de barras (categorías)
- Gráfico de sectores (proporciones)

Explicación ejemplo

Aquí se puede ver una explicación para aclarar conceptos: [EJEMPLO](#)

Conceptos esenciales: frecuencias

FRECUENCIA ABSOLUTA (f_i)

Número de elementos que toma un determinado valor de la variable. Cuantifica cuántas veces aparece un valor en los datos.

FRECUENCIA ACUMULADA (F_i)

Suma sucesiva de las frecuencias absolutas de los distintos valores de las variables.

FRECUENCIA RELATIVA (f_i/n)

Número de elementos con un valor determinado dividido por el total de elementos (n). Proporción.

PORCENTAJE (%)

Frecuencia relativa multiplicada por 100. Expresa la proporción en términos porcentuales.

PORCENTAJES ACUMULADOS

Suma sucesiva de los porcentajes de los distintos valores. El último valor tiene un porcentaje de 100.

Explicación Frecuencias

Aquí se puede ver una explicación para aclarar conceptos: [EJEMPLO](#)

Ejemplo: tabla de distribución de frecuencias

A partir de 50 observaciones (valores 0–4), construimos la tabla de distribución de frecuencias contando cuántas veces aparece cada valor.

Xi	fi (abs.)	Fi (acum.)	fi/n (rel.)	%	% Acum.
0	9	9	0,18	18,0	18,0
1	16	25	0,32	32,0	50,0
2	13	38	0,26	26,0	76,0
3	8	46	0,16	16,0	92,0
4	4	50	0,08	8,0	100,0

Medidas de tendencia central

Resumen del conjunto de datos a través de un valor representativo. Indican hacia dónde tienden los datos.

MEDIA ($\bar{x}$)

$$\Sigma xi / n$$

Suma de todos los valores dividida entre el número de observaciones. Sensible a valores extremos (outliers).

Datos: 2, 4, 4, 6, 8 $\rightarrow$ Media = $24/5 = 4,8$

MEDIANA

Valor central

Valor que divide el conjunto de datos en dos partes iguales cuando están ordenados. Robusta ante outliers.

Datos: 2, 4, 4, 6, 8 $\rightarrow$ Mediana = 4

MODA

Valor más frecuente

El valor que aparece con mayor frecuencia. Un conjunto puede tener una, varias o ninguna moda.

Datos: 2, 4, 4, 6, 8 $\rightarrow$ Moda = 4

Medidas de dispersión

Indican cuánto se alejan los datos del valor central. Miden la variabilidad del conjunto de datos.

RANGO

$$\text{Max} - \text{Min}$$

Diferencia entre el valor máximo y el mínimo. Muy simple pero muy sensible a outliers.

VARIANZA (σ^2)

$$\Sigma(xi - \bar{x})^2 / n$$

Promedio de los cuadrados de las desviaciones respecto a la media. Siempre positiva.

DESVIACIÓN ESTÁNDAR (σ)

$$\sqrt{\text{varianza}}$$

Raíz cuadrada de la varianza. En las mismas unidades que los datos. La más usada en la práctica.

Representaciones gráficas



Diagrama de barras

Para variables categóricas. Representa frecuencias con barras de altura proporcional.



Histograma

Para variables continuas. Las barras representan intervalos de valores con sus frecuencias.



Gráfico de sectores

Muestra proporciones de un total. Ideal para pocas categorías bien diferenciadas.



Diagrama de dispersión

Muestra la relación entre dos variables cuantitativas. Detecta correlaciones.

La media aritmética en detalle

La media aritmética

Es el promedio de todos los valores del conjunto de datos. Es la medida de tendencia central más utilizada en estadística descriptiva.

Fórmula

$$\bar{x} = (x_1 + x_2 + \dots + x_n) / n$$

Suma de todos los valores dividida entre n.

Ventaja

Usa todos los datos. Operaciones matemáticas sencillas. Muy intuitiva.

Desventaja

Sensible a valores atípicos (outliers). Un solo valor extremo puede distorsionarla significativamente.

Ejemplo práctico

Messi marcó 0,9 goles por partido en promedio durante toda su carrera en el FC Barcelona.

Medidas de forma: asimetría y curtosis

ASIMETRÍA

Positiva (derecha): Cola larga hacia la derecha. $\text{Media} > \text{Mediana} > \text{Moda}$.

Simétrica: Distribución equilibrada. $\text{Media} = \text{Mediana} = \text{Moda}$.

Negativa (izquierda): Cola larga hacia la izquierda. $\text{Media} < \text{Mediana} < \text{Moda}$.

CURTOSIS

Leptocúrtica: Más puntiaguda que la normal. $\text{Curtosis} > 3$. Más datos concentrados en el centro.

Mesocúrtica: Similar a la distribución normal. $\text{Curtosis} \approx 3$.

Platicúrtica: Más aplastada que la normal. $\text{Curtosis} < 3$. Datos más dispersos.

Medidas de posición: cuartiles y percentiles

Las medidas de posición dividen el conjunto de datos ordenados en partes iguales, permitiendo conocer la distribución relativa de los valores.

CUARTILES (Q)

Dividen los datos en 4 partes iguales.

Q1 (25%): primer cuartil

Q2 (50%): mediana

Q3 (75%): tercer cuartil

$IQR = Q3 - Q1$ (rango intercuartil)

DECILES (D)

Dividen los datos en 10 partes iguales.

D1 equivale al percentil 10.

D5 equivale a la mediana (Q2).

D9 equivale al percentil 90.

PERCENTILES (P)

Dividen los datos en 100 partes iguales.

P25 = Q1

P50 = Mediana

P75 = Q3

P90: el 90% de los datos está por debajo.

Diagrama de caja y bigotes (Boxplot)

El Boxplot

Es una representación gráfica que resume cinco estadísticos clave de un conjunto de datos:

- Valor mínimo
- Q1 (percentil 25)
- Mediana Q2 (percentil 50)
- Q3 (percentil 75)
- Valor máximo

También muestra valores atípicos (outliers) como puntos fuera de los bigotes.

Es muy útil para comparar distribuciones entre grupos y detectar asimetrías y outliers rápidamente.

Estructura visual



$IQR = Q3 - Q1$ (rango intercuartil)
Datos entre bigotes: valores típicos
Puntos fuera: outliers

Medidas de asociación

Las medidas de asociación cuantifican la relación o dependencia entre dos o más variables. Son fundamentales en el análisis bivalente.

CORRELACIÓN DE PEARSON (r)

Mide la fuerza y dirección de la relación lineal entre dos variables cuantitativas.

$r = 1$: correlación perfecta positiva
 $r = -1$: correlación perfecta negativa
 $r = 0$: sin correlación lineal

Requiere variables de intervalo o cociente.

COEF. DE CONTINGENCIA

Mide la asociación entre dos variables cualitativas (nominales u ordinales).

Se basa en la tabla de contingencia. Toma valores entre 0 y 1.

0: sin asociación
1: máxima asociación posible

CORRELACIÓN DE SPEARMAN (ρ)

Alternativa no paramétrica a Pearson.

Usa los rangos de los datos, no los valores originales.

Más robusta ante outliers y válida para variables ordinales.

Interpretación similar a Pearson: de -1 a +1.

Resumen: estadística descriptiva

Conceptos básicos

Población, muestra, elemento, variable, observación, caso

Tipos de variables

Cualitativas (nominal, ordinal) · Cuantitativas (intervalo, cociente) · Continuas/discretas

Tendencia central

Media, mediana, moda

Dispersión

Rango, varianza, desviación estándar

Posición

Cuartiles, deciles, percentiles, boxplot

Forma

Asimetría (positiva, simétrica, negativa) · Curtosis

Frecuencias

Absoluta, acumulada, relativa, porcentajes

Representaciones

Barras, histograma, sectores, dispersión, boxplot

Asociación

Pearson, Spearman, coeficiente de contingencia

¿Qué es la media?

Media ($\bar{x}$ o μ)

Suma de todos los valores dividida entre el tamaño del conjunto de datos.

Es la estadística de posición más utilizada y fácil de calcular.

Funciona bien cuando la distribución es simétrica y no hay outliers.

Se denota con barra x ($\bar{x}$) o con la letra griega μ (mu) para poblaciones.

Fórmula

$$\bar{x} = (x_1 + x_2 + \dots + x_n) / n$$

n = número de datos

Ejemplo

Datos: 2, 4, 6, 8, 10

Suma = 30

n = 5

$$\bar{x} = 30 / 5 = 6$$

¿Qué es la mediana?

La mediana es el valor medio que deja exactamente la mitad de los datos por encima y la otra mitad por debajo. Es robusta ante outliers, a diferencia de la media.

¿Cuándo usarla?

Se utiliza cuando los datos no son simétricos o cuando existen outliers que podrían distorsionar la media.

Requisito previo

¡Los valores deben estar ordenados de menor a mayor antes del cálculo!

Número impar de valores

La mediana es el valor que queda exactamente en la mitad del conjunto ordenado.

Número par de valores

La mediana es la media aritmética de los dos valores centrales del conjunto ordenado.

Ejemplo: cálculo de la mediana

Número IMPAR de datos

Datos ordenados:

23, 33, 34, 36, →38←, 40, 41, 41, 44

Mediana = 38 (valor central, posición 5ª de 9)

→ 4 valores por encima · 4 valores por debajo

Número PAR de datos

Datos ordenados:

12, 30, 31, 37, →38, 40←, 41, 41, 44, 45

Mediana = $(38 + 40) / 2 = 39$
(media de los dos valores centrales)

→ 4 valores por encima · 4 valores por debajo

¿Cuándo difieren la media y la mediana?

La presencia de outliers (valores atípicos) afecta a la media mucho más que a la mediana. Un solo valor extremo puede desplazar la media considerablemente, especialmente en conjuntos pequeños.

SIN outlier

Datos: 1, 2, 3, 4, 5

Media = 3 · Mediana = 3

✓ Media y mediana coinciden

CON outlier

Datos: 1, 2, 3, 4, 100

Media = 22 · Mediana = 3

⚠ La media se dispara, la mediana es robusta

Conclusión: cuando los datos tienen outliers o son asimétricos, la mediana es más representativa del centro de los datos que la media.

La moda

La moda es el valor que aparece con mayor frecuencia en un conjunto de datos. Es la única medida de tendencia central aplicable a variables cualitativas.

UNIMODAL

Un solo pico. Solo hay un valor que se repite más que los demás.

Ejemplo: 1, 2, 3, 3, 3, 4, 5 → Moda = 3

BIMODAL

Dos picos. Dos valores se repiten con la misma frecuencia máxima.

Ejemplo: 1, 2, 2, 3, 4, 4, 5 → Moda = 2 y 4

MULTIMODAL

Tres o más picos. Múltiples valores con la misma frecuencia máxima.

Útil para detectar grupos o subpoblaciones en los datos.

Nota: la moda rara vez se usa como medida de tendencia central. Su mayor utilidad es distinguir entre distribuciones uni- y multimodales.

Medidas de posición no centrales

Las medidas de posición no centrales dividen el conjunto de datos ordenados en partes iguales, indicando qué proporción de los datos queda por debajo de un punto concreto.

PERCENTILES — 100 partes

$$P_{25} = Q_1, P_{50} = \text{Mediana}, P_{75} = Q_3$$

Dividen los datos en 100 partes iguales. El percentil P indica que ese porcentaje de datos está por debajo de ese valor.

Ej: Percentil 25 $\rightarrow$ el 25% de datos está por debajo.

DECILES — 10 partes

$$D_1 = P_{10}, D_5 = P_{50}, D_9 = P_{90}$$

Dividen los datos en 10 partes iguales. El decil 3 indica que el 30% de los datos está por debajo de ese valor.

D_5 equivale a la mediana.

CUARTILES — 4 partes

$$Q_1 = 25\%, Q_2 = 50\%, Q_3 = 75\%$$

Dividen los datos en 4 partes iguales. El rango intercuartílico ($IQR = Q_3 - Q_1$) mide la dispersión central.

Q_2 coincide con la mediana.

QUINTILES — 5 partes

$$\text{Cada quintil} = 20\% \text{ de los datos}$$

Dividen los datos en 5 partes iguales. Cada quintil corresponde al 20% de los datos.

Menos utilizados que cuartiles o percentiles.

Medidas de dispersión

La dispersión indica cómo se desvían los datos de su medida de posición central. Da una indicación de la cantidad de variación que presentan los datos.

Ejemplo real: en procesos de fabricación, es un indicador clave de la calidad y se utiliza para controlar la variabilidad de la producción.



RANGO

Diferencia entre el valor máximo y el mínimo.
La medida más sencilla de variabilidad.



VARIANZA (σ^2 / s^2)

Promedio de los cuadrados de las desviaciones respecto a la media. Siempre positiva.



DESVIACIÓN ESTÁNDAR

Raíz cuadrada de la varianza. En las mismas unidades que los datos. La más usada.

El rango

$$\text{Rango} = \text{Valor máximo} - \text{Valor mínimo}$$

- Es la medida más sencilla de la variabilidad.
- Suficiente en muchos casos prácticos para analizar la dispersión del conjunto.
- Sin embargo, no aprovecha al máximo los datos disponibles.
- Puede ser engañosa cuando los datos están sesgados o cuando existen outliers.

Efecto de los outliers

Sin outlier:

1, 2, 3, 4, 5

$$\text{Rango} = 5 - 1 = 4$$

Con outlier:

1, 2, 3, 4, 100

$$\text{Rango} = 100 - 1 = 99$$

⚠ El rango aumenta de 4 a 99 por un solo valor extremo.

La desviación estándar

La desviación estándar es la distancia media de los puntos de datos respecto a su propia media. Es la medida más sólida de la variabilidad de un conjunto de datos.

Fórmula (muestra)

$$s = \sqrt{[\Sigma(x_i - \bar{x})^2 / (n-1)]}$$

s = desviación estándar muestral · $\bar{x}$ = media · n = nº de datos

Pasos para calcularla

1. Calcula la media ($\bar{x}$).
2. Resta la media a cada valor: $(x_i - \bar{x})$.
3. Eleva cada resultado al cuadrado: $(x_i - \bar{x})^2$.
4. Suma todos los cuadrados: $\Sigma(x_i - \bar{x})^2$.
5. Divide entre $(n - 1)$.
6. Aplica la raíz cuadrada.

Desviación BAJA

Los datos están agrupados en torno a la media. Poca variabilidad.

Desviación ALTA

Los datos están muy dispersos alrededor de la media. Alta variabilidad.

La varianza

La varianza es una medida de la variación en torno a la media. Mide la distancia al cuadrado que separa un conjunto de puntos de datos de su media.

Fórmula

Varianza = s^2

$$s^2 = \sum (x_i - \bar{x})^2 / (n-1)$$

Es el cuadrado de la desviación estándar.

Unidades

Las unidades son el cuadrado de las unidades originales.

Ej: si la variable es en metros $\rightarrow$ la varianza es en m^2 .

Interpretación

Cuanto mayor es la varianza, más dispersos están los datos respecto a la media.

Varianza = 0 $\rightarrow$ todos los datos son idénticos.

Relación con σ

Desviación estándar = $\sqrt{\text{Varianza}}$

La desviación estándar es más intuitiva porque tiene las mismas unidades que los datos originales.

Medidas de forma: asimetría y curtosis

La forma de la distribución puede revelar mucha información sobre los datos. Se puede visualizar mediante un histograma. Los datos siempre siguen una distribución conocida.

1

La forma ayuda a identificar qué estadística descriptiva es más apropiada para cada situación.

2

Si los datos son simétricos, se puede usar tanto la media como la mediana para medir la tendencia central.

3

Si los datos son asimétricos, la mediana será más apropiada que la media como medida de tendencia central.

4

Los dos estadísticos de forma más importantes son la Asimetría (Skewness) y la Curtosis (Kurtosis).

Distribuciones: simétricas y asimétricas

SIMÉTRICA

Los dos lados de la distribución son imagen especular el uno del otro.

Media = Mediana = Moda

Ejemplos:

- Distribución normal (campana de Gauss)
- Distribución uniforme

Indica equilibrio en la distribución de los datos.

ASIMÉTRICA

Positiva (derecha):

Cola larga hacia la derecha.

Moda < Mediana < Media

Negativa (izquierda):

Cola larga hacia la izquierda.

Media < Mediana < Moda

Distribuciones asimétricas frecuentes:

- Ingresos (asimétrica positiva)
- Tiempos de respuesta (asimétrica positiva)
- Notas en exámenes fáciles (negativa)

Asimetría (Skewness)

La asimetría (SK) describe si los datos se distribuyen simétricamente en torno a la media. Un valor $SK = 0$ indica simetría perfecta.

SIMÉTRICA ($SK = 0$)

$$\text{Skewness} = 0$$

Simetría perfecta. Las dos partes a ambos lados de la mediana son iguales.

Moda = Mediana = Media

Distribución normal o campana de Gauss.

ASIMÉTRICA POSITIVA ($SK > 0$)

$$\text{Skewness} > 0$$

Datos sesgados a la derecha. La cola derecha es más alargada.

Moda < Mediana < Media

Ejemplo: ingresos, precios de vivienda.

ASIMÉTRICA NEGATIVA ($SK < 0$)

$$\text{Skewness} < 0$$

Datos sesgados a la izquierda. La cola izquierda es más alargada.

Media < Mediana < Moda

Ejemplo: edad de jubilación, notas en exámenes fáciles.

Curtosis (Kurtosis)

La curtosis mide el grado de apuntamiento de una distribución. Indica si los datos se concentran más o menos en el centro respecto a una distribución normal.

MESOCÚRTICA

$$\text{Curtosis} \approx 0$$

Apuntamiento similar a la distribución normal. Sirve como referencia.

Los datos están distribuidos de forma estándar.

PLATICÚRTICA

$$\text{Curtosis} < 0$$

Distribución más aplastada que la normal.
Los datos están repartidos más uniformemente.

Cola más corta, pico más bajo.

LEPTOCÚRTICA

$$\text{Curtosis} > 0$$

Distribución más apuntada que la normal.
Los datos se agrupan mucho en el centro.

Cola más larga y pesada, pico muy alto.

La campana de Gauss y la distribución normal

Gráfico de probabilidad normal

La distribución normal es la más importante en estadística. Su forma de campana simétrica se usa para:

- Identificar valores atípicos.
- Comprobar si los datos se ajustan a la distribución normal.
- Comparar diferentes distribuciones.
- Calcular probabilidades.

El eje horizontal representa los valores de la variable y el eje vertical la frecuencia o probabilidad de ese valor.

Propiedades clave

- Media = Mediana = Moda
- Simétrica respecto a la media
- 68% datos en $\pm 1\sigma$ de la media
- 95% datos en $\pm 2\sigma$ de la media
- 99,7% datos en $\pm 3\sigma$ de la media
- Campana asintótica (no toca el eje)

Formas básicas de representación gráfica

Las representaciones gráficas permiten explorar visualmente los datos para detectar patrones, tendencias, outliers y distribuciones de forma rápida e intuitiva.



Gráfico de sectores

Variables cualitativas (nominales)

Muestra proporciones sobre el total. Área de cada sector = porcentaje de esa categoría.



Diagrama de barras

Variables cuantitativas (discretas)

Barras separadas. Altura de cada barra = frecuencia o porcentaje.



Histograma

Variables continuas agrupadas

Barras unidas. Anchura = amplitud del intervalo. Área = frecuencia.



Diagrama de dispersión

Relación entre 2 variables métricas

Nube de puntos. Muestra la relación o correlación entre dos variables.



Línea de grafos

Variables temporales / evolutivas

Un valor por cada punto del eje X. Muestra tendencias a lo largo del tiempo.



Boxplot

Distribución y outliers

Muestra Q1, mediana, Q3, bigotes y outliers. Compara distribuciones.

Gráfico de sectores



Representación gráfica en forma de círculo.

¿Cuándo usarlo?

- Preferentemente para variables cualitativas, sobre todo nominales.
- El total del área del círculo representa el 100% de la distribución.
- Cada sector circular representa el porcentaje de elementos en cada categoría.
- Ideal para pocas categorías (máximo 5–6) bien diferenciadas entre sí.
- No recomendado cuando las categorías tienen proporciones muy similares.

Ejemplo: deporte favorito (n=50)

Fútbol	16	32%
Baloncesto	13	26%
Tenis	9	18%
Surf	9	18%
Golf	3	6%

Diagrama de barras




Barras separadas, una por cada valor o categoría de la variable.

Características

- La altura de cada barra representa la frecuencia o porcentaje de cada valor o categoría.
- Las barras están separadas entre sí (no contiguas como en el histograma).
- Preferentemente para variables cuantitativas discretas y variables cualitativas ordinales.
- Permite comparar fácilmente las frecuencias entre diferentes categorías.

Ejemplo: veces al cine (n=50)



Número de veces / mes

Histograma




Barras unidas, una por cada intervalo de valores de la variable.

Diferencias con el diagrama de barras

- Las barras están UNIDAS (no separadas), representando intervalos continuos.
- La anchura de cada barra = amplitud del intervalo de valores.
- El área de cada barra representa la frecuencia o porcentaje del intervalo.
- Preferentemente para variables cuantitativas continuas, cuyos valores se agrupan en intervalos.

Distribución de frecuencias



(forma de campana normal)

Diagrama de dispersión y línea de grafos



Diagrama de dispersión

Representación de dos variables métricas a la vez: una en el eje X y otra en el eje Y.

También llamado nube de puntos.

Por cada valor de la variable en X puede haber más de un valor en Y.

Permite detectar:

- Relación lineal o no lineal
- Correlación positiva o negativa
- Grupos de puntos (clusters)
- Valores atípicos (outliers)



Línea de grafos

Representación de al menos dos variables métricas conectadas por una línea.

Por cada valor de X solo puede haber UN valor de Y (diferencia clave con el diagrama de dispersión).

Cuando el eje X es temporal, la línea muestra la EVOLUCIÓN de la variable Y a lo largo del tiempo.

Usos frecuentes:

- Evolución de ventas
- Series temporales
- Indicadores financieros

Box plot (diagrama de caja y bigotes)

¿Qué muestra el boxplot?

Representa en un solo gráfico los siguientes estadísticos clave:

- Valor mínimo
- Q1 (percentil 25)
- Mediana / Q2 (percentil 50)
- Q3 (percentil 75)
- Valor máximo
- Outliers (puntos fuera de los bigotes)

El rango intercuartílico ($IQR = Q3 - Q1$) es la longitud de la caja.

Los bigotes se extienden hasta $1,5 \times IQR$ desde Q1 y Q3.

Utilidades del boxplot

1. Identificar la presencia de outliers o valores extremos.
2. Comparar la distribución de varios conjuntos de datos.
3. Evaluar la simetría de la distribución.
4. Comparar la dispersión en diferentes grupos.

¿Cómo analizar un gráfico?

Al analizar cualquier gráfico estadístico, puedes sacar conclusiones basándote en las siguientes preguntas sistemáticas:

1

¿Dónde está el centro?

Localiza el centro aproximado del gráfico. ¿Dónde se concentran la mayoría de los datos? Esto te da la tendencia central.

2

¿Cómo están repartidos los valores?

Analiza la dispersión. ¿Están los datos muy juntos o muy separados? ¿Hay mucha variabilidad?

3

¿Cuál es la forma general?

Observa la forma: ¿es simétrica? ¿Es asimétrica? ¿Tiene uno o varios picos? ¿Es acampanada, uniforme o irregular?

4

¿Hay algún patrón interesante?

Busca outliers, grupos, tendencias temporales, ciclos u otras características inusuales que requieran investigación adicional.

Detección de outliers (valores atípicos)

La forma más fácil de detectar outliers es graficando los datos. Un outlier es un punto de datos que se aleja significativamente del resto del conjunto.

HISTOGRAMA

Los outliers aparecen como barras aisladas lejos del cuerpo principal de la distribución. Útil para detectar grupos de outliers.

BOXPLOT

Los outliers se representan como puntos fuera de los bigotes (más allá de $1,5 \times \text{IQR}$). Es el método gráfico más eficaz.

GRÁFICO DE PROB. NORMAL

Los outliers se alejan de la línea recta de referencia. Permite evaluar simultáneamente normalidad y presencia de atípicos.

¿Qué hacer con un outlier?

Error experimental

Puede indicar un error en la medición o en el registro de los datos. → EXCLUIR si hay evidencia.

Ocorre por casualidad

Puede ser un valor real, aunque poco probable. → Analizar antes de decidir.

Dato correcto

Algunos procesos generan valores extremos de forma natural. → MANTENER en el análisis.