

B I G D A T A

Unidad 3

Identificación de conceptos técnicos
de la analítica tradicional

IFCT0022 Big Data

3.1 La analítica tradicional

3.2 Estadística descriptiva

3.3 Álgebra lineal

3.4 Correlaciones

3.5 Contrastes de hipótesis

Índice de contenidos

3.1 La analítica tradicional

3.2 Introducción a la estadística descriptiva

3.3 Introducción al álgebra lineal

3.4 Correlaciones

3.5 Contrastes de hipótesis

3.1

¿Qué es la analítica tradicional?



COMENZAR

¿Qué es la analítica tradicional?

1

La "analítica tradicional" se refiere a los enfoques del análisis de datos que existían antes de la aparición del Big Data y la Inteligencia Artificial.

2

Se remonta a cuando los datos eran limitados en volumen y variedad. Usa técnicas estadísticas y matemáticas consolidadas para extraer conocimiento.

3

En la era del Big Data, es esencial entender cómo la analítica tradicional se adapta e integra en este nuevo contexto tecnológico.

Características principales



Recopilación y preparación

Datos estructurados en tablas. Limpieza y transformación antes del análisis.



Análisis descriptivo

Gráficos, tablas resumen y estadísticas para explorar el comportamiento de los datos.



Análisis inferencial

Pruebas de hipótesis, intervalos de confianza y regresión estadística.



Aplicaciones en decisiones

Negocios, economía, ciencias sociales, salud. Determina efectividad de estrategias.

Más características



Enfoque en datos históricos

Análisis de tendencias y patrones a lo largo del tiempo para entender el rendimiento pasado.



Herramientas convencionales

SPSS, SAS, R y Excel. Diseñadas para análisis estadístico y matemático.



Escalabilidad limitada

Dificultades con grandes volúmenes de datos no estructurados o semiestructurados propios de la era digital.

Analítica convencional vs. contemporánea

Aspecto	Analítica Convencional	Analítica Contemporánea
Escala de datos	Datos estructurados, menor volumen	Big Data: estructurados y no estructurados en tiempo real
Técnicas	Estadísticas descriptivas e inferenciales	ML, IA, NLP
Fuente de datos	Fuentes internas principalmente	Internas + redes sociales, sensores, IoT
Decisiones	Información retrospectiva	Información prospectiva y predictiva
Herramientas	SPSS, Excel	Python, R, Hadoop, Spark, TensorFlow
Velocidad	Más lento (menor volumen)	Más rápido: paralelización y procesamiento distribuido

3.2

Introducción a la estadística descriptiva



COMENZAR

¿Qué es la estadística?

La estadística es la ciencia que se ocupa de la recogida, clasificación, presentación e interpretación de la información numérica. Es el estudio de los datos que se obtienen de fenómenos repetibles.

¿Por qué la necesitamos?

Para saber por qué un proceso se comporta como lo hace.

Para reducir la variabilidad y mejorar la capacidad del proceso.

Para conocer la verdad sobre el mundo real.

Conceptos básicos de la estadística

POBLACIÓN

Conjunto total de objetos, personas o eventos a estudiar. Ej: todos los estudiantes matriculados en una universidad.

MUESTRA

Subconjunto representativo de la población. Los resultados obtenidos deben poder generalizarse a toda la población.

ELEMENTO

Unidad de análisis. Cualquier cosa que pueda ser identificada y estudiada en un contexto específico.

Conceptos básicos (continuación)

VARIABLE

Característica que se mide en cada elemento. Ej: estatura, edad o género de los estudiantes.

OBSERVACIÓN

Valor de una variable para un elemento concreto. Ej: el peso de cada estudiante en una escuela.

CASO

Conjunto de observaciones para un elemento. Ej: cada árbol individual en un estudio de crecimiento forestal.

Tipos de variables: cualitativas

Variables NO MÉTRICAS, CUALITATIVAS o CATEGÓRICAS: representan cualidades o características que no pueden ser medidas numéricamente.

NOMINALES

Representan categorías SIN orden específico.

Ejemplo: el color de un automóvil (rojo, azul, verde).

No existe una relación de magnitud entre las categorías.

ORDINALES

Representan categorías CON orden específico.

Ejemplo: clasificación de película (1-5 estrellas) o nivel educativo (primaria, secundaria, universidad).

Existe jerarquía, pero la distancia entre valores no es constante.

Tipos de variables: cuantitativas

Variables MÉTRICAS o CUANTITATIVAS: representan cantidades numéricas medibles con precisión.

VARIABLE DE INTERVALO

Escala numérica con distancias uniformes pero SIN punto cero absoluto.

Ejemplo: temperatura en °C o °F. La diferencia entre 10° y 20° es igual que entre 20° y 30°, pero 0° no significa ausencia de temperatura.

VARIABLE COCIENTE

Escala numérica con distancias uniformes y CON punto cero verdadero.

Ejemplo: peso en kg. Tiene un cero absoluto (ausencia total de peso). Permite afirmar que 40 kg es el doble de 20 kg.

Variables continuas vs. discretas



CONTINUAS

Pueden tomar CUALQUIER valor dentro de un rango determinado.

No hay saltos entre valores.

Ejemplos:

- Altura de una persona
- Temperatura del aire
- Tiempo en completar una tarea



DISCRETAS

Solo pueden tomar valores ENTEROS o específicos de una lista definida.

Existen saltos entre valores posibles.

Ejemplos:

- Número de hijos en una familia
- Número de estudiantes en clase
- Número de ventas diarias

Variables según su papel en el análisis

DEPENDIENTES

Son las variables que se estudian y se intentan explicar. Son el resultado o efecto que se quiere analizar.

INDEPENDIENTES

Las que están relacionadas o predicen la variación de la variable dependiente. Son la causa o factor que influye.

INTERVINIENTES O DE CONTROL

Las que ayudan a explicar o matizan la relación entre la variable independiente y la dependiente.

Ejemplo: El ejercicio físico (independiente) → reducción del estrés (dependiente) → controlado por la edad de los participantes (interviniente).

Tipos de estadística



DESCRIPTIVA

Usa métodos gráficos para interpretar los datos mejor. Describe, resume y organiza los datos para que sean fácilmente comprensibles.

Incluye medidas de tendencia central, dispersión, frecuencias y representaciones gráficas.



INFERENCIAL

Usa las matemáticas para modelar y predecir variaciones. Permite hacer inferencias sobre poblaciones basadas en muestras.

Incluye pruebas de hipótesis e intervalos de confianza.

La estadística descriptiva

La estadística descriptiva es una rama de la estadística que se enfoca en la descripción, el resumen y la presentación de los datos de una muestra o población.

- Medidas de tendencia central: media, mediana, moda.

- Medidas de forma: asimetría y curtosis.

- Frecuencias absolutas, relativas y porcentajes.

- Medidas de dispersión: rango, varianza y desviación típica.

- Representaciones gráficas: sectores, barras, histograma, dispersión.

- Medidas de asociación: correlación de Pearson, coeficiente de contingencia.

Categorías de la estadística descriptiva



UNIVARIADA

Análisis de una SOLA variable. Utiliza medidas de tendencia central, dispersión y gráficos sencillos.



BIVARIADA

Análisis de DOS variables y su relación. Usa correlación, regresión lineal simple, tablas de contingencia.



MULTIVARIANTE

Análisis de DOS O MÁS variables. Técnicas: análisis factorial, regresión múltiple, componentes principales.

Distribuciones univariantes

Las técnicas más comunes de descripción univariante incluyen:

Medidas de tendencia central (media, mediana, moda) · Medidas de dispersión (desviación estándar, rango, varianza) · Representaciones gráficas (histogramas, diagramas de barras, gráficos de sectores).

Tendencia Central

- Media (promedio)
- Mediana (valor central)
- Moda (valor más frecuente)

Dispersión

- Rango (max - min)
- Varianza (dispersión cuadrática)
- Desviación estándar ($\sqrt{\text{varianza}}$)

Representación gráfica

- Histograma (datos continuos)
- Diagrama de barras (categorías)
- Gráfico de sectores (proporciones)

Explicación ejemplo

Aquí se puede ver una explicación para aclarar conceptos: [EJEMPLO](#)

Conceptos esenciales: frecuencias

FRECUENCIA ABSOLUTA (f_i)

Número de elementos que toma un determinado valor de la variable. Cuantifica cuántas veces aparece un valor en los datos.

FRECUENCIA ACUMULADA (F_i)

Suma sucesiva de las frecuencias absolutas de los distintos valores de las variables.

FRECUENCIA RELATIVA (f_i/n)

Número de elementos con un valor determinado dividido por el total de elementos (n). Proporción.

PORCENTAJE (%)

Frecuencia relativa multiplicada por 100. Expresa la proporción en términos porcentuales.

PORCENTAJES ACUMULADOS

Suma sucesiva de los porcentajes de los distintos valores. El último valor tiene un porcentaje de 100.

Explicación Frecuencias

Aquí se puede ver una explicación para aclarar conceptos: [EJEMPLO](#)

Ejemplo: tabla de distribución de frecuencias

A partir de 50 observaciones (valores 0–4), construimos la tabla de distribución de frecuencias contando cuántas veces aparece cada valor.

Xi	fi (abs.)	Fi (acum.)	fi/n (rel.)	%	% Acum.
0	9	9	0,18	18,0	18,0
1	16	25	0,32	32,0	50,0
2	13	38	0,26	26,0	76,0
3	8	46	0,16	16,0	92,0
4	4	50	0,08	8,0	100,0

Total: 50 observaciones · n = 50

Medidas de tendencia central

Resumen del conjunto de datos a través de un valor representativo. Indican hacia dónde tienden los datos.

MEDIA ($\bar{x}$)

$$\Sigma xi / n$$

Suma de todos los valores dividida entre el número de observaciones. Sensible a valores extremos (outliers).

Datos: 2, 4, 4, 6, 8 $\rightarrow$ Media = $24/5 = 4,8$

MEDIANA

Valor central

Valor que divide el conjunto de datos en dos partes iguales cuando están ordenados. Robusta ante outliers.

Datos: 2, 4, 4, 6, 8 $\rightarrow$ Mediana = 4

MODA

Valor más frecuente

El valor que aparece con mayor frecuencia. Un conjunto puede tener una, varias o ninguna moda.

Datos: 2, 4, 4, 6, 8 $\rightarrow$ Moda = 4

Medidas de dispersión

Indican cuánto se alejan los datos del valor central. Miden la variabilidad del conjunto de datos.

RANGO

$$\text{Max} - \text{Min}$$

Diferencia entre el valor máximo y el mínimo. Muy simple pero muy sensible a outliers.

VARIANZA (σ^2)

$$\Sigma(xi - \bar{x})^2 / n$$

Promedio de los cuadrados de las desviaciones respecto a la media. Siempre positiva.

DESVIACIÓN ESTÁNDAR (σ)

$$\sqrt{\text{varianza}}$$

Raíz cuadrada de la varianza. En las mismas unidades que los datos. La más usada en la práctica.

Representaciones gráficas



Diagrama de barras

Para variables categóricas. Representa frecuencias con barras de altura proporcional.



Histograma

Para variables continuas. Las barras representan intervalos de valores con sus frecuencias.



Gráfico de sectores

Muestra proporciones de un total. Ideal para pocas categorías bien diferenciadas.



Diagrama de dispersión

Muestra la relación entre dos variables cuantitativas. Detecta correlaciones.

La media aritmética en detalle

La media aritmética

Es el promedio de todos los valores del conjunto de datos. Es la medida de tendencia central más utilizada en estadística descriptiva.

Fórmula

$$\bar{x} = (x_1 + x_2 + \dots + x_n) / n$$

Suma de todos los valores dividida entre n.

Ventaja

Usa todos los datos. Operaciones matemáticas sencillas. Muy intuitiva.

Desventaja

Sensible a valores atípicos (outliers). Un solo valor extremo puede distorsionarla significativamente.

Ejemplo práctico

Messi marcó 0,9 goles por partido en promedio durante toda su carrera en el FC Barcelona.

Medidas de forma: asimetría y curtosis

ASIMETRÍA

Positiva (derecha): Cola larga hacia la derecha. $\text{Media} > \text{Mediana} > \text{Moda}$.

Simétrica: Distribución equilibrada. $\text{Media} = \text{Mediana} = \text{Moda}$.

Negativa (izquierda): Cola larga hacia la izquierda. $\text{Media} < \text{Mediana} < \text{Moda}$.

CURTOSIS

Leptocúrtica: Más puntiaguda que la normal. $\text{Curtosis} > 3$. Más datos concentrados en el centro.

Mesocúrtica: Similar a la distribución normal. $\text{Curtosis} \approx 3$.

Platicúrtica: Más aplastada que la normal. $\text{Curtosis} < 3$. Datos más dispersos.

Medidas de posición: cuartiles y percentiles

Las medidas de posición dividen el conjunto de datos ordenados en partes iguales, permitiendo conocer la distribución relativa de los valores.

CUARTILES (Q)

Dividen los datos en 4 partes iguales.

Q1 (25%): primer cuartil

Q2 (50%): mediana

Q3 (75%): tercer cuartil

$IQR = Q3 - Q1$ (rango intercuartil)

DECILES (D)

Dividen los datos en 10 partes iguales.

D1 equivale al percentil 10.

D5 equivale a la mediana (Q2).

D9 equivale al percentil 90.

PERCENTILES (P)

Dividen los datos en 100 partes iguales.

P25 = Q1

P50 = Mediana

P75 = Q3

P90: el 90% de los datos está por debajo.

Diagrama de caja y bigotes (Boxplot)

El Boxplot

Es una representación gráfica que resume cinco estadísticos clave de un conjunto de datos:

- Valor mínimo
- Q1 (percentil 25)
- Mediana Q2 (percentil 50)
- Q3 (percentil 75)
- Valor máximo

También muestra valores atípicos (outliers) como puntos fuera de los bigotes.

Es muy útil para comparar distribuciones entre grupos y detectar asimetrías y outliers rápidamente.

Estructura visual



$IQR = Q3 - Q1$ (rango intercuartil)

Datos entre bigotes: valores típicos

Puntos fuera: outliers

Medidas de asociación

Las medidas de asociación cuantifican la relación o dependencia entre dos o más variables. Son fundamentales en el análisis bivalente.

CORRELACIÓN DE PEARSON (r)

Mide la fuerza y dirección de la relación lineal entre dos variables cuantitativas.

$r = 1$: correlación perfecta positiva
 $r = -1$: correlación perfecta negativa
 $r = 0$: sin correlación lineal

Requiere variables de intervalo o cociente.

COEF. DE CONTINGENCIA

Mide la asociación entre dos variables cualitativas (nominales u ordinales).

Se basa en la tabla de contingencia. Toma valores entre 0 y 1.

0: sin asociación
1: máxima asociación posible

CORRELACIÓN DE SPEARMAN (ρ)

Alternativa no paramétrica a Pearson.

Usa los rangos de los datos, no los valores originales.

Más robusta ante outliers y válida para variables ordinales.

Interpretación similar a Pearson: de -1 a +1.

Resumen: estadística descriptiva

Conceptos básicos

Población, muestra, elemento, variable, observación, caso

Tipos de variables

Cualitativas (nominal, ordinal) · Cuantitativas (intervalo, cociente) · Continuas/discretas

Tendencia central

Media, mediana, moda

Dispersión

Rango, varianza, desviación estándar

Posición

Cuartiles, deciles, percentiles, boxplot

Forma

Asimetría (positiva, simétrica, negativa) · Curtosis

Frecuencias

Absoluta, acumulada, relativa, porcentajes

Representaciones

Barras, histograma, sectores, dispersión, boxplot

Asociación

Pearson, Spearman, coeficiente de contingencia