



4.3 Construir un Proyecto de Big Data

Ciclo de vida, metodología estructurada y fases críticas para la consecución con éxito de iniciativas de analítica masiva en el ecosistema corporativo actual.

Fases del Proyecto Big Data (Pasos 1 a 4)



1. Definir Objetivo

Comprender a fondo la actividad comercial y definir los entresijos específicos del negocio.



2. Obtener Datos

Identificar las fuentes, integrarlas en el pipeline y conectarse a almacenes y APIs.



3. Limpiar Datos

Eliminar ruidos, registros vacíos e incoherencias de los formatos de origen.



4. Enriquecer

Mejorar la representatividad juntando datasets y creando nuevas variables lógicas.

Fases del Proyecto Big Data (Pasos 5 a 7)



5. Encontrar Insights

Representar gráficamente la información estructurada mediante herramientas BI para agilizar la toma de decisiones estratégicas.



6. Machine Learning

Desplegar algoritmos inteligentes y predictivos sobre una arquitectura robusta para extraer patrones de comportamiento.



7. Iterar del Proceso

Un proyecto Big Data nunca concluye por completo; es un ciclo continuo y recursivo de mejora y optimización de datos.

Paso 1: Definición Rigurosa del Objetivo



Comprensión del Negocio

Para garantizar el éxito de la analítica, es imperativo entender con absoluta precisión cómo se mueve la empresa y su mercado.

- > Entender los flujos internos y cuellos de botella reales.
- > Saber exactamente qué retos operativos se pretenden paliar.



Definición de Métricas

La estrategia debe materializarse en variables de negocio medibles y tangibles (Plan de Hitos estructurado).

- > **KPIs:** Indicadores Clave de Rendimiento operativos.
- > **KERs:** Resultados Clave Esperados tras la ingesta.

Paso 2: Obtener y Localizar los Datos



Estrategias de Búsqueda

La obtención de datos debe alinearse estrictamente con los objetivos planteados en la fase de negocio previa.

- > Análisis del mapa de silos de datos internos.
- > Selección de variables críticas para el análisis del negocio.



Vías Técnicas de Adquisición

Existen diversos métodos estructurados para nutrir nuestro almacén o data warehouse.

- > **Bases de Datos:** Conexiones a estructuras existentes.
- > **APIs Comerciales:** Interconexión con servicios externos.
- > **Web Scraping:** Extracción automática de datos abiertos.

La Clasificación de Orígenes de Datos



Datos Corporativos

Sistemas internos CRM, ERP e historiales transaccionales clave que definen el núcleo operativo histórico de la empresa.



Social Media & IoT

Ecosistemas Web, redes de sensores embebidos y APIs de comportamiento de plataformas e interacciones sociales.



Datos Públicos

Catálogos abiertos de administraciones públicas y bases de datos libres listos para ser incorporados al pipeline analítico.

Tipos de Datos según su Estructura



Estructurados (Baja Complejidad)

Organizados en filas y columnas perfectamente delimitadas bajo un esquema estricto relacional.

- > Fácilmente recolectados y procesados.
- > Ejemplos: PostgreSQL, MySQL, archivos CSV formateados.



Semi y No Estructurados (Alta Complejidad)

Carecen de **esquema fijo**, requiriendo procesamientos lógicos intermedios avanzados para su interpretación útil.

- > **No Estructurados:** Vídeos, audios, imágenes y textos planos.
- > **Semi-estructurados:** XML, JSON y ficheros log de red.



Anatomía de la Información Web

Análisis de las capas de información que componen la red mundial de servidores: desde la web indexada hasta el almacenamiento oculto en darknets.

La Realidad de la Deep Web y la Dark Web




Estructura Oculta de Internet

No toda la información web es accesible de la misma forma para los algoritmos rastreadores y motores de búsqueda.

- > **Deep Web:** Páginas protegidas o no indexadas que representan más del 90% del volumen real de Internet.
- > **Dark Web:** Una ínfima porción de la Deep Web de carácter anónimo e intencionadamente cifrada.
- > Requiere protocolos específicos (como Tor) y proxies para la extracción y modelado seguro de datos.

DEEP WEB VS DARK WEB



Paso 3: La Vital Importancia de la Limpieza

80%

Tiempo del Científico de Datos

La Tarea Crítica del Pipeline

El criterio central para que un data warehouse o lago de datos sea operativo es la consistencia, limpieza y nula corrupción de la información ingerida.

- > Fase más laboriosa de cualquier arquitectura Big Data.
- > Garantiza la viabilidad de los modelos de negocio y del posterior machine learning.
- > **Leyes de Privacidad:** Esencial anonimizar y cumplir normativas como el RGPD europeo.

Anomalías Críticas a Detectar



El Peligro de los Valores NULL

Un valor nulo mal gestionado en el pipeline puede corromper severamente los cálculos y uniones de tablas.

- > En bases SQL tipo MySQL, Los campos NULL entre la table principal y FORANEA no se pueden igualar (**NULL no es igual a NULL**, provocando fallas críticas en Joins.
- > Requiere auditorías rigurosas previas de claves foráneas.



Tratamiento de Fechas y Formatos

Las fechas son elementos peculiares porque pueden representarse de decenas de formas lógicas distintas. DDMMYYYY, MMDDYY

- > Diferentes valores textuales con exactamente el mismo significado.
- > Es imperativo estandarizar a un único formato nativo de destino.

Paso 4: Enriquecimiento del Conjunto



Aumento de Valor de los Datos

Consiste en inyectar capas de contexto adicionales para maximizar la calidad final del análisis descriptivo y predictivo.

- > Cruzar y unificar datasets de fuentes dispares.
- > Generar métricas consolidadas .



Facilitar el Aprendizaje Algorítmico

Un conjunto enriquecido disminuye exponencialmente el esfuerzo de cálculo de las redes neuronales.

- > Combinación lógica de columnas y segmentaciones.
- > Generar intervalos temporales a partir de fechas en bruto.

Paso 5: Encontrar Insights Estratégicos



Microsoft PowerBI

Plataforma líder orientada a la creación de cuadros de mando dinámicos con amplia conectividad con data warehouses.



Grafana Dashboards

Visualización orientada a la monitorización de telemetría en tiempo real y series temporales IoT industriales complejas.



Tableau Software

Motor analítico de gran potencia visual perfecto para investigadores de datos que buscan detectar patrones ocultos de forma ágil.

Paso 6: Despliegue de Aprendizaje Automático



Modelado Algorítmico

Utilizar matemáticas avanzadas aplicadas a computación para revelar correlaciones imposibles de discernir por analistas humanos.

- > **Clustering (No Supervisado):** Agrupación automática de perfiles por comportamiento analógico.
- > **Predicciones (Supervisado):** Estimaciones de valor futuro basadas en series e históricos.



Arquitectura Operativa

No basta con tener el modelo matemático; este debe integrarse en la infraestructura diaria y en producción.

- > Ejecución de inferencias automatizadas constantes.
- > Mantenimiento recurrente de la infraestructura predictiva.

Paso 7: La Ley de la Iteración Infinita

***NUNCA terminaremos de tener todo al 100% terminado
de iterar o mejorar. Siempre queda algo más.***



4.4 El Proceso ETL

Extracción, Transformación y Carga: El motor de tuberías de datos (pipelines) que alimenta los sistemas analíticos modernos garantizando la máxima calidad.

El Pipeline de Procesamiento ETL




¿Qué define a un flujo ETL?

Un pipeline ETL es un conjunto integrado de procesos informáticos que orquestan el movimiento del dato entre orígenes dispares y destinos unificados.

- **E (Extracción):** Captura controlada y limpia en sistemas fuente.
- **T (Transformación):** Conversión lógica, filtrado y normalización en el área de staging.
- **L (Carga - Load):** Consolidación persistente e indexada en el Warehouse de la empresa.

Three Components of ETL Process Flow Model

This slide is 100% editable. Adapt it to your needs and capture your audience's attention.



Fase 1: Extracción de Datos



Objetivo Primordial

Recuperar toda la información requerida del sistema de origen impactando mínimamente en el rendimiento operativo diario de las bases de datos de producción.

- > Evitar caídas de rendimiento transaccional.
- > Hacer accesibles los datos para procesamiento en Staging.



Vías de Extracción

La ingesta de datos puede realizarse mediante metodologías diferenciadas según la naturaleza del origen.

- > **Extracción Lógica:** Métodos automatizados basados en el software y metadatos.
- > **Extracción Física:** Volcados de bits directos en archivos planos o copias externas.

Comparativa de Estrategias

Estrategia	Descripción Técnica del Proceso	Caso de Uso Recomendado	Impacto Operativo
Lógica Completa	Extracción y carga integral por primera vez de la totalidad del dataset disponible en origen.	Migración inicial de bases de datos de clientes.	Elevado consumo de red e infraestructura.
Lógica Incremental	Se rastrean y cargan exclusivamente las diferencias y cambios de datos desde la última actualización.	Sincronizaciones diarias de facturación.	Bajo. Requiere marcas de tiempo estructuradas.
Física En Línea	Conexión interactiva directa al motor fuente transaccional en tiempo real.	Consumo de APIs de pasarelas de pago.	Crítico. Puede afectar transacciones concurrentes.
Física Fuera de Línea	Lectura indirecta de archivos planos o volcados generados por rutinas automáticas programadas.	Procesamiento de Logs históricos masivos.	Prácticamente nulo sobre servidores principales.

Fase 2: Transformación de Datos



Nivel de Registro

Operaciones de selección y filtrado masivo, uniones complejas (Joins), agregación y normalización completa de las filas de origen.

Nivel de Campo

Transformación de campos únicos o generación de variables uniendo varias columnas. Ejemplo:
nombre + apellido1 + apellido2



Staging Area

Las transformaciones nunca alteran el origen inicial;
se ejecutan en un área operativa segura intermedia.



Fin Segunda Parte

Hemos cubierto el ciclo metodológico Big Data y las dos fases ETL (Extracción y Transformación).

Siguiente Sesión del Curso:

Fase de Carga (Load) y Enfoque Organizacional "Data Driven"



La Zona de Staging y el Proceso de Calidad del Dato

Estudio detallado del área intermedia de almacenamiento operativo y las rutinas sistemáticas para asegurar la exactitud, consistencia y homogeneidad de la información antes de su ingesta definitiva.

La Zona de Parada o Staging Area



¿Qué es el Área de Staging?

Una **zona intermedia** de almacenamiento utilizada durante la ejecución de los procesos ETL para volcar datos brutos de manera transitoria.

- > **Permite leer los datos exactamente como estaban en origen.**
- > Protege **los sistemas fuente de sobrecargas** de procesamiento continuo.
- > Soporta de manera aislada la fase de transformación.



Reglas Operativas Críticas

La zona de staging cuenta con directrices de seguridad y control de accesos dentro del flujo empresarial.

- > **Aislamiento de fases:** Si la transformación falla, no se repite la extracción.
- > **Acceso restringido:** Solamente el proceso ETL puede consultar el área.
- > **Prohibición a usuarios:** El usuario final jamás debe visualizar datos en staging.

El Paradigma de la Calidad del Dato



Correcto y Preciso

Los registros almacenados deben representar fielmente la realidad transaccional del negocio, sin errores tipográficos o desviaciones métricas fuera de contexto.



Sin Ambigüedades

Cada campo de datos debe tener un formato y una definición perfectamente clara, facilitando su lectura sin interpretaciones subjetivas o formatos confusos.



Coherente y Completo

La información debe estar cohesionada entre tablas y no presentar lagunas conceptuales o desconexiones lógicas de **integridad referencial**.

Detección de Anomalías Críticas



Rutinas de Comprobación Directas

Se ejecutan inspecciones exhaustivas de forma paralela en dos momentos clave: inmediatamente tras la extracción y al finalizar el proceso de depuración.

- > Muestreo estructurado y recuento estricto de filas por grupo.
- > Verificación de las propiedades y tipología intrínseca de las columnas.



Puntos Críticos de Alerta

Variables y patrones sospechosos que deben activar alertas automáticas en el pipeline antes de su inserción en el warehouse:

- > Presencia de valores nulos o campos en blanco inesperados.
- > Valores numéricos que caen fuera de los máximos y mínimos típicos.
- > Longitudes de columna excepcionalmente cortas o largas.
- > Valores que no corresponden a conjuntos discretos definidos.

Corrección de Errores y Depuración



Corrección de Errores Críticos

Las anomalías semánticas o estructurales deben ser subsanadas de inmediato en el pipeline antes de continuar hacia el destino analítico.

- > Faltas de ortografía graves y fechas fuera de rango histórico.
- > Eliminación de registros duplicados idénticos.
- > Resolución de inconsistencias lógicas en uso de campos.



Procesamientos Auxiliares de Ingesta

Tareas complejas adicionales que garantizan la usabilidad general del conjunto de datos empresarial:

- > **Decodificación:** Traducción de códigos crudos a texto legible.
- > **Sellado de tiempo:** Registro cronológico exacto de la carga.
- > **Fusión y Claves:** Generación de claves primarias artificiales.



La Fase de Carga (Load) en Sistemas ETL

Consolidación final de la información procesada en el repositorio analítico centralizado, comparando estrategias de carga completa frente a cargas incrementales optimizadas.

Estrategias de Carga en ETL



La Carga Completa (Full Load)

Consiste en volcar la totalidad del dataset de golpe al sistema de destino, reemplazando o truncando la información persistente.

- > Se utiliza principalmente en la puesta en marcha inicial del almacén.
- > Mantiene la última fecha de extracción vacía.
- > Fácil de validar pero sumamente costosa en recursos de red.



La Carga Incremental (Incremental Load)

Inyección controlada de las diferencias detectadas (registros nuevos o modificados) en intervalos regulares de tiempo.

- > Requiere marcas de tiempo claras para identificar cambios.
- > Optimiza los tiempos de procesamiento en sistemas masivos.
- > Compleja de orquestar de manera lógica por la herramienta ETL.

La Ventana de Tiempo Nocturna

8h
Ventana de Carga Crítica

¿Por qué priorizar la Carga Incremental?

El factor insalvable de la velocidad y el rendimiento técnico.

En entornos con volúmenes de Big Data masivos, las operaciones analíticas deben ocurrir por la noche, buscando que la información actualizada esté lista antes de la jornada comercial.

- > La carga completa de Terabytes puede requerir más de 24 horas continuas.
- > La carga incremental aprovecha la ventana nocturna de manera óptima.

Comparativa de Cargas en Almacenes de Datos

Criterio Técnico	Carga Completa (Full Load)	Carga Incremental (Incremental)
Acción Inicial	Trunca o vacía todas las filas e inserta desde cero.	Conserva los datos previos e inserta/actualiza cambios.
Consumo de Tiempo	Elevado. Crece de manera proporcional al volumen histórico.	Reducido. Se limita a procesar los últimos cambios diarios.
Garantía de Consistencia	Sencilla. No requiere lógica de comparación de duplicados.	Alta complejidad. Requiere analizar claves y timestamps.
Tratamiento de Datos Caídos	Se vuelve a correr la carga sin riesgo de duplicar datos.	Requiere control de transacciones para no perder delta de cambios.



4.5 El Enfoque **Data-Driven** en la Empresa

Estrategia y cultura corporativa orientada a la toma de decisiones basada exclusivamente en la evidencia y el análisis de los datos recogidos.

La Empresa Orientada a Datos (Data-Driven)



La Cultura Basada en Evidencia

Las organizaciones maduras tecnológicamente dejan atrás las **decisiones intuitivas** o basadas en corazonadas de la gerencia tradicional.

- > Democratización del acceso a la información útil en todos los niveles.
- > Soporte de hipótesis con reportes y cuadros analíticos fiables.
- > Reducción del margen de error en lanzamientos comerciales.



Infraestructura de Medición

Para materializar el enfoque Data-Driven, la empresa requiere de una pila tecnológica de recolección y reporting robusta:

- > Cuadros de mando integrados con PowerBI o Tableau.
- > Conexión fluida con los almacenes corporativos depurados.
- > Estandarización de métricas y KPIs unificados por área.

Reporting versus Análisis de Datos

Parámetro Comparativo	Reporting de Negocio (Informes)	Análisis de Datos Avanzado
Enfoque Temporal	Retrospectivo. Mira al pasado para describir qué ocurrió.	Prospectivo y predictivo. Intenta adelantarse al futuro.
Objetivo Principal	Descriptivo. Mide volumen de ventas, inventario y KPIs.	Prescriptivo. Sugiere cambios y acciones automatizadas.
Generación de Valor	Muestra datos brutos organizados en cuadros de mando.	Transforma la información en intuición y valor estratégico.
Interacción Operativa	Lanza preguntas sobre el desempeño de la empresa.	Responde de forma científica y predictiva a esas preguntas.


La Importancia de la Visualización



Facilitar la Toma de Decisiones

Las representaciones visuales interactivas y dinámicas permiten descifrar de manera instantánea miles de filas crudas de datos.

- Diseño de cuadros de mando (dashboards) jerárquicos.
- Detección rápida de cuellos de botella mediante mapas de calor.
- Sistemas de alertas automatizados por desviaciones de margen.





4.6 Caso de Estudio: El Sector Eléctrico

Análisis de la revolución que introduce el Big Data, los sensores de red e IoT en el modelo clásico de distribución, transformando la infraestructura en una Smart Grid bidireccional.

Agentes en el Ecosistema Energético



Los Usuarios y Autoproductores

El cliente moderno exige más que una simple provisión de energía estática de un único sentido.

- > Conectividad bidireccional para venta de excedentes.
- > Tarificación variable en tiempo real y libre elección.
- > Fomento de generación individual fotovoltaica limpia.



Compañías de Redes Eléctricas

Operadores que deben asegurar la integridad de la red equilibrando de manera dinámica la inyección y el consumo.

- > Control sistemático de fluctuaciones en baja y media tensión.
- > Ahorro tangible por eficiencias en transporte.
- > Trazabilidad del ahorro por hábitos de consumo.


Sistemas Fotovoltaicos y Autoconsumo



Flujo Bidireccional de Energía

La integración de paneles solares residenciales o comerciales transforma los flujos de consumo clásicos.

- > **Generación:** Los paneles solares inyectan energía limpia al hogar o red.
- > **Inversor:** Transforma la corriente continua en alterna útil.
- > **Medidor Bidireccional:** Registra de forma separada el consumo de la red y el excedente inyectado.



La Red Inteligente o Smart Grid



Millones de Sensores

Incorporación masiva de telemetría IoT a lo largo de toda la red de subestaciones y puntos de consumo intermedios.



Comunicaciones IoT

Protocolos de comunicaciones avanzados para la adquisición en tiempo real de variaciones de tensión y carga de transformadores.



Cómputo Distribuido

Procesamiento Big Data en el perímetro de la red para una actuación predictiva ante picos de demanda energética.

La Transición del Modelo de Gestión de Red



Beneficios del Smart Grid y la Automatización

- >  **Disminución de Tiempos de Corte:** Localización inmediata de la anomalía sin requerir patrullas físicas de inspección a lo largo de las líneas.
- >  **Ajuste Dinámico de Tarifas:** Incentivos económicos directos al usuario para desplazar consumos pesados a horas de baja demanda.
- >  **Reducción del Impacto Ambiental:** Integración dinámica y fluida de energías renovables intermitentes como la eólica y solar.
- >  **Evitación de Sanciones:** Minimización de multas regulatorias gubernamentales impuestas a las concesionarias por interrupciones del servicio.

Inteligencia Geoespacial en Redes



Reducción Drástica de Tiempos de Fallo

La combinación del mapeo geográfico GIS con sensores IoT en subestaciones permite resolver incidencias de manera ágil.

- **Ahorro del 80%:** Localización instantánea de cortocircuitos sobre el mapa urbano.
- **FDIR Automático:** Detección de fallas, aislamiento lógico y restauración remota de secciones sanas en milisegundos.





4.7 Perfiles Profesionales de Big Data

Definición y taxonomía de roles indispensables para orquestar y desplegar con éxito infraestructuras robustas de analítica masiva en el entorno empresarial.

El Ingeniero de Datos y el Arquitecto



El Ingeniero de Datos (Data Engineer)

El perfil técnico que recibe el flujo bruto y desordenado del exterior para transformarlo en conjuntos limpios y estructurados.

- > Manejo experto de base de datos SQL y NoSQL.
- > Sólidos conocimientos de Python, Java o Scala.
- > Creación de pipelines ETL/ELT fiables.



El Arquitecto de Big Data

El encargado de diseñar y supervisar la infraestructura multinivel que soporta el ciclo de vida completo del dato corporativo.

- > Definición de tecnologías híbridas locales y Cloud (AWS/Azure).
- > Orquestación con ecosistemas Hadoop, Spark y Kafka.
- > Garantía de rendimiento ante accesos concurrentes.

El Analista de Datos y el Científico



El Analista de Datos (Data Analyst)

El rol orientado al negocio corporativo que convierte los datos procesados en respuestas útiles y visualizaciones dinámicas.

- > Uso avanzado de Power BI, Tableau, Carto y Grafana.
- > Generación sistemática de KPIs para directivos.
- > Gran desarrollo de habilidades interpersonales y de comunicación.



El Científico de Datos (Data Scientist)

Perfil con enfoque matemático riguroso e investigador que explora hipótesis complejas de I+D a medio y largo plazo.

- > Fuerte formación estadística y académica.
- > Descubrimiento de correlaciones no obvias en los datos.
- > Prototipado de modelos de modelado predictivo.

Especialista en Inteligencia Artificial



Especialista en Inteligencia Artificial

El perfil encargado de materializar las predicciones complejas automatizando algoritmos heurísticos en la infraestructura real.

- > Despliegue de modelos de Machine y Deep Learning.
- > Optimización de pesos de redes neuronales artificiales.
- > Perfil altamente cotizado con requerimiento de aprendizaje continuo.



Simbiosis de Roles Corporativos

El éxito de un entorno Big Data corporativo reside en la estrecha comunicación de este equipo multidisciplinar:

- > El Arquitecto y el Ingeniero proveen la infraestructura limpia.
- > El Científico y el Especialista en IA modelan patrones predictivos.
- > El Analista traduce y comunica los insights resultantes al negocio.



¡Excelente!

Final de la Unidad Temática 4.

Resumen de Hitos

- > Comprensión de aplicaciones prácticas y marco tecnológico global.
- > Ciclo metodológico completo de proyectos de Big Data.
- > Anatomía del pipeline ETL e infraestructura de Smart Grids.
- > Mapeo de perfiles profesionales corporativos del ecosistema.