

Módulo 5: Big Data

Manual de apuntes y analítica avanzada para el curso de capacitación profesional
IFCT0022.

5.1 Introducción

Ecosistema general, fases analíticas y fundamentos de almacenamiento masivo.

| Fases Clave del Ciclo de Big Data



Almacenar

Consolidación física y lógica de los registros garantizando accesibilidad y seguridad sobre infraestructuras elásticas.



Procesar

Conversión, limpieza y cálculo distribuido sobre los datos masivos estructurados o desestructurados.



Analizar

Descubrimiento de tendencias profundas, correlaciones y valor empírico mediante modelos predictivos.

| NoSQL vs. Bases de Datos Relacionales

Modelos NoSQL

Perfectos para Big Data debido a su alta escalabilidad horizontal. No exigen esquemas fijos de tablas, permitiendo procesar datos no estructurados con alta velocidad de lectura/escritura.

Modelos Relacionales [RDBMS]

Limitados para entornos masivos distribuidos, pero cruciales si se exige absoluta integridad transaccional (ACID) y consistencia en los datos del negocio tradicional.

| Beneficios del Almacenamiento Optimizado

- ✓ **Escalabilidad de Volumen:** Capacidad inmediata para asimilar inmensas colecciones de datos en bruto sin degradar la infraestructura física.
- ✓ **Analítica en Tiempo Real:** Reducción de tiempos de latencia para optimizar la toma de decisiones empresariales inmediatas.
- ✓ **Descubrimiento de Patrones:** Identificación quirúrgica de tendencias operativas, patrones de riesgo y posibilidades de fraude.
- ✓ **Sistemas Personalizados:** Confección de servicios de valor añadido ajustados directamente a la experiencia real del usuario.

5.2 Arquitecturas y Flujos


Estructuración técnica para el procesamiento masivo y escalable de información.

Arquitectura de Almacenamiento

Esquema por Capas

El diseño jerárquico separa la capa de adquisición e ingesta de datos en bruto de la capa de cómputo secuencial o streaming.

Esto permite a las organizaciones optimizar la redundancia del hardware y procesar terabytes de datos de forma paralela usando clusters escalables como HDFS o servicios web distribuidos.



| Comparativa de Sistemas de Almacenamiento

Sistema	Ventajas Analíticas	Desafío Crítico
NoSQL (Cassandra)	Esquema flexible, escalabilidad lineal masiva.	Manejo de consultas estructuradas complejas.
Relacionales (RDBMS)	Absoluta consistencia operativa (ACID).	Baja tolerancia a escalado horizontal.
Cloud (Amazon S3 / GCP)	Coste flexible de entrada, nula gestión física.	Dependencia de conectividad de red externa.
Sistemas Distribuidos (HDFS)	Tolerancia a fallos automática y alta resiliencia.	Configuración administrativa avanzada.

| El Desafío Absoluto del Volumen

90
%

**Datos Generados
Recientemente**

Crecimiento Exponencial

La inmensa mayoría de la información global disponible hoy ha sido creada en los últimos dos años mediante canales digitales, telemetría y sensores. Esta vertiginosa velocidad de generación fuerza la transición desde bases relacionales clásicas hacia arquitecturas distribuidas de computación.

| Desafíos y Soluciones del Procesamiento



Velocidad

Solución: Motores de datos interactivos en streaming y memoria integrada como Apache Spark.



Variedad


Solución: Esquemas dinámicos flexibles y frameworks NoSQL para asimilar textos e imágenes.



Veracidad

Solución: Pipelines inteligentes de control de calidad, normalización y políticas estrictas de Gobierno de Datos.

| Procesamiento según Requisitos Temporales



La mayor parte de los análisis empresariales continúan resolviéndose bajo modelos Batch consolidados, aunque el crecimiento del Streaming dinámico en sectores IoT es el que empuja las inversiones actuales.

5.2 Arquitecturas de Tiempo Real

Estrategias de ingesta, procesamiento distribuidos de flujos y cómputo perimetral (Edge).

| Tiempo Real vs. Procesamiento por Lotes

Baja Latencia [Streaming]

Las arquitecturas en streaming resuelven la velocidad de respuesta. Procesan datos dinámicos en milisegundos sin acumular histórico, lo que requiere infraestructuras y diseños de red más complejos.

Alta Latencia [Batch]

El procesamiento por lotes acumula datos para procesar volúmenes masivos simultáneamente. Son arquitecturas más sencillas de implementar y tolerantes a fallos (con opción de reejecución completa).

| Estrategias de Integración de Fuentes



File Tailing & Appender

Captura secuencial de las líneas finales agregadas a ficheros logs activos, consolidando la información de manera continuada en el sistema.



Sondeo SQL & CDC

Extracción periódica o captura instantánea de cambios (Change Data Capture) en bases de datos relacionales para mantener las réplicas sincronizadas.



Flujos de Sensores

Ingesta ininterrumpida de ráfagas de datos procedentes de hardware y redes de sensores distribuidos (telemetría directa en tiempo real).

| Integración de Flujos vs. Análisis de Flujos

Criterio Técnico	Integración de Datos de Flujo	Análisis de Flujos (Streaming Analytics)
Enfoque Principal	Involucra la obtención e ingesta limpia desde múltiples fuentes.	Orientado a la analítica compleja y detección de patrones de negocio.
Lógica Operativa	Pipelines ETL, filtrado, conversión y enrutamiento de formatos.	Cálculo de agregados temporales y correlación de eventos (CEP).
APIs Comunes	APIs de bajo nivel, JSON declarativo y herramientas basadas en GUI.	Consultas mediante Streaming SQL y APIs fluidas de alto nivel.
Gestión del Estado	Generalmente sin estado (Stateless) para agilizar la ingesta.	Con estado persistente (Stateful) para mantener memorias de trabajo.

| Paradigma de Consumo: Evento vs. Micro-batch

Evento a la Vez [Event-at-a-Time]

Cada registro entrante se procesa de forma individual en el instante en que arriba al sistema. Asegura la latencia mínima absoluta, ideal para respuestas automatizadas inmediatas.

Microlotes [Micro-batch]

Agrupar flujos continuos en bloques temporales diminutos antes de lanzarlos al motor de procesamiento. Maximiza el rendimiento del hardware y simplifica la tolerancia a fallos.

| Garantías de Entrega de Mensajería



At Most Once

Como máximo una vez. Modelo rápido de "fuego y olvido". No se realizan retransmisiones; se prioriza la velocidad ante posibles pérdidas de datos.



At Least Once

Al menos una vez. Se asegura la entrega mediante retransmisiones continuas hasta obtener confirmación (puede generar mensajes duplicados).



Exactly Once

Exactamente una vez. El sistema garantiza de forma lógica la entrega única sin pérdidas ni repeticiones, requiriendo un control de estado riguroso.

5.3 Analítica de Patrones y Anomalías

Identificación de irregularidades y modelado de comportamientos repetitivos mediante IA.

| Tipologías de Anomalías en Big Data



Anomalías Puntuales

Eventos individuales que se desvían drásticamente de la norma general en un punto de datos específico (por ejemplo, un pico aislado en ventas).



Colectivas e Históricas

Secuencias coordinadas de eventos que, evaluados en conjunto, exponen desviaciones significativas a lo largo de un intervalo temporal.



Contextuales o Cíclicas

Datos normales bajo ciertas circunstancias estacionales que se convierten en anomalías absolutas si se presentan en contextos incorrectos.

| Técnicas Clave de Identificación de Patrones

- ✓ **Análisis de Correlación & Clustering:** Identifica dependencias mutuas entre métricas y agrupa flujos por similitud geométrica para clasificar comportamientos.
- ✓ **Series Temporales & Desviación:** Modelado matemático del comportamiento histórico de variables para inferir tendencias ascendentes o decrecientes a futuro.
- ✓ **Causalidad & Ausencias:** Revela la conexión de causa-efecto entre variables u orienta alertas operativas ante la falta repentina de flujos de datos.

5.4 Casos de Estudio de Big Data

Estudio técnico de implementaciones e infraestructuras empresariales reales.

| Análisis de Clickstream en Tienda Online

- **Ingesta en Tiempo Real:** Flume recopila las coordenadas de clicks e interacciones de sesión, enviándolas en streaming a Apache Kafka.
- **Procesamiento Inteligente:** Spark y Spark MLlib evalúan los flujos de forma continua para entrenar modelos predictivos de compra.
- **Persistencia y Explotación:** Los históricos de perfiles y resultados analíticos se almacenan de manera elástica en HBase y Hive para reportes.

