

Módulo 5: Big Data

Manual de apuntes avanzados para el curso IFCT0022. Arquitecturas Lambda/Kappa, análisis en tiempo real, detección de patrones de anomalías y ecosistema de nube en Amazon Web Services.

5.3 Arquitecturas e IoT

Estrategias avanzadas de computación distribuida y procesamiento analítico de flujos para baja latencia.

| Caso de Uso: Mantenimiento Predictivo

Ingesta e Histórico

Las métricas críticas de las máquinas industriales se extraen mediante Talend o Sqoop/Flume. Estos flujos alimentan un histórico masivo persistente en HDFS para posteriores calibraciones del modelo analítico.

Predicción y Alerta

Spark MLlib entrena y ejecuta algoritmos de aprendizaje automático para predecir fallos mecánicos de forma proactiva. Los resultados se guardan en HBase y se explotan mediante herramientas tradicionales de BI.

| Mapeo Tecnológico: Lote vs. Streaming

Capa Técnica	Enfoque Batch (Lotes Tradicionales)	Enfoque Streaming (Tiempo Real)
Recogida de Datos	Sqoop, Talend, Oracle Data Integrator.	Apache Flume, Apache Kafka, GoldenGate.
Cómputo / Procesamiento	Hadoop MapReduce, Apache Spark Core.	Spark Streaming, Apache Storm, Apache Samza.
Almacenamiento Final	HDFS, Amazon S3, Oracle Database.	Apache HBase, Cassandra, Oracle NoSQL.
Acceso e Informes	Apache Hive, cloudera Impala, Spark SQL.	Elasticsearch, Microservicios, APIs directas.

5.4 Paradigmas Lambda y Kappa

Estructuras de diseño de sistemas de datos de alto rendimiento y robustez analítica.

| Arquitectura Lambda vs. Kappa

Paradigma Lambda

Combina una capa rápida de streaming (baja latencia) con una de batch (alta precisión). Aunque conserva un histórico inmutable, exige implementar y mantener la misma funcionalidad lógica dos veces.

Paradigma Kappa

Elimina la capa por lotes tradicional. Todos los datos se tratan como un flujo ininterrumpido a través de un procesador de eventos rápido (como Kafka). Simplifica el código pero requiere re-ejecución sobre logs.

| Ingesta de Sensores e IoT



Dispositivos MQTT

Captura ininterrumpida de ráfagas métricas de telemetría industrial de baja potencia mediante protocolos optimizados de red de sensores.



Procesamiento Rápido

Utilización de Spark Streaming, Storm o Samza para evaluar y filtrar eventos complejos en tiempo real a medida que se desplazan.



Persistencia Elástica

Almacenamiento directo de las anomalías detectadas en repositorios NoSQL altamente escalables como Apache Cassandra o HBase.

| El Reto de Escala en NASDAQ

8.000M

**Transacciones
Diarias**

Racionalización de Costes con la Nube

NASDAQ migró su infraestructura de almacenamiento tradicional (con coste de 1,16 millones de dólares anuales y límite de retención de un año) a la nube de AWS. Esta estrategia les permite asimilar hasta 8.000 millones de registros de órdenes y cotizaciones por sesión de manera eficiente y escalable para tareas de vigilancia de mercado y facturación.

5.5 Big Data en la Nube (AWS)

Estrategias de recolección elástica, almacenamiento distribuido y procesamiento de datos gestionado en Amazon Web Services.

| Pipeline de Procesamiento AWS



1. Recolectar

Captura elástica de streams web o métricas IoT mediante Amazon Kinesis o AWS Direct Connect.



2. Almacenar

Persistencia elástica y segura en S3 para archivos, DynamoDB para NoSQL y RDS Aurora para transaccional.



3. Procesar


Cómputo de eventos sin servidores mediante AWS Lambda y clústeres elásticos con Amazon EMR.



4. Analizar

Visualización interactiva y consultas masivas con Amazon Redshift, QuickSight y Machine Learning.

| Simulación de Costes por Hora



$$C_{\text{Total}} = C_{\text{S3}} + C_{\text{Redshift}} + C_{\text{Kinesis}} = 2.90 \text{ \$/hora}$$

Simulación para un procesamiento de escala masiva de 500 millones de tweets diarios (~1 TB/día). La infraestructura escalable se despliega y destruye elásticamente, pagando únicamente por el consumo operacional real.

Buenas Prácticas

Adapte siempre las arquitecturas Lambda o Kappa a sus necesidades particulares operativas de negocio.

Módulo 5: Big Data

Casos de estudio avanzados y análisis comparativos. De la infraestructura masiva de NASDAQ al procesamiento sensorizado de Kaiten Sushiro y la cartera elástica de Google Cloud Platform (GCP).

Caso de Estudio: NASDAQ

Análisis del replanteamiento de almacenamiento, escalado masivo e ingesta segura en la bolsa de valores.

| Migración a Amazon Redshift

Inyección de Registros

Cada sesión de trading de NASDAQ inyecta una media de 5.500 millones de registros de cotizaciones directamente en su repositorio analítico basado en Amazon Redshift.

Eficiencia y Costes

La arquitectura in situ basada en HDFS se volvió demasiado cara de mantener y escalar. La adopción de Amazon S3 junto a Elastic Map Reduce (EMR) cerró la brecha de costes con éxito.

| Seguridad Integrada en Amazon Redshift



Seguridad Física y de Red

Nodos de cómputo protegidos de accesos directos de internet, integrados de forma nativa con Amazon VPC para aislamiento completo.



Cifrado Total

Datos en tránsito protegidos mediante SSL. Cifrado AES-256 por hardware para datos persistidos tanto en S3 como en disco duro.



Auditoría y KMS

Historial exhaustivo de logs de actividad e integración profunda con AWS CloudTrail y Key Management Service (KMS).

| Infraestructura de Consultas Seguras



Arquitectura de Clúster Redshift


El cliente realiza consultas seguras mediante JDBC/ODBC que acceden a un nodo líder de Redshift en su propia VPC. El nodo líder coordina las tareas a través de conexiones internas HPC de 10 GigE hacia los nodos de computación paralela de la base de datos. Las copias de seguridad continuas y la restauración se canalizan directamente de manera aislada hacia Amazon S3 y tablas optimizadas de DynamoDB.

Caso Dropcam: Vídeo Masivo

El Reto del Crecimiento Explosivo

Dropcam comenzó como un servicio de videovigilancia simple para hogares, pero experimentó un crecimiento exponencial que de repente elevó su almacenamiento a petabytes de grabaciones de vídeo.

Para mitigar la carga de infraestructura física, migraron todo su almacenamiento e ingesta a AWS, confiando en DynamoDB para metadatos rápidos y S3 para flujos continuos CVR (Cloud Video Recording).



| El Pipeline Tecnológico de Dropcam

Transmisión y Entrega

Utilización de instancias EC2 y servidores dedicados para streaming de vídeo en vivo de cámaras IP. El contenido grabado en S3 se sirve eficientemente a usuarios finales mediante Amazon CloudFront (CDN).

Visión por Computador y EMR

El procesamiento pesado para el reconocimiento automatizado de actividad se realiza mediante algoritmos de computer vision integrados sobre clústeres de Amazon EMR, alertando a los usuarios rápidamente.

| Caso Sushiro: IoT en el Restaurante



Kaiten Sushi Inteligente

La famosa cadena japonesa de restaurantes Sushiro implementó chips RFID debajo de cada plato de sushi que recorre las cintas transportadoras.

Los sensores leen en tiempo real qué platos se consumen, cuáles llevan demasiado tiempo circulando (y deben ser desechados de forma segura) y calculan de forma instantánea la demanda futura de comida.

| El Flujo Sensorizado de Sushiro

Ingesta con Kinesis

Las lecturas de RFID en los platos de comida son transmitidas mediante pasarelas locales hacia internet. Amazon Kinesis captura estos flujos continuos en tiempo real con latencias de milisegundos.

Análisis y Visualización

Un servicio personalizado de Kinesis procesa y limpia las lecturas, enviándolas a Amazon Redshift. Finalmente, se explotan mediante Tableau para optimizar la preparación de sushi en cocina.

Google Cloud Platform

Exploración de la cartera de servicios e infraestructuras avanzadas de Google para Big Data.

| Modelos de Servicio en la Nube de Google



IaaS [Infraestructura]

Servicios informáticos adaptables como Google Compute Engine para crear y ejecutar máquinas virtuales de manera flexible y escalable.



PaaS [Plataforma]

Entornos totalmente gestionados y libres de servidores como Google App Engine para desplegar aplicaciones sin administrar sistemas operativos.



SaaS [Software]

Aplicaciones integradas y terminadas directamente listas para el consumo del usuario final, tales como Gmail o el ecosistema Workspace.

| Cómputo en GCP: Compute vs. App Engine

Google Compute Engine [GCE]

Ofrece virtualización tradicional de servidores con redimensión de disco en línea, redes virtuales, firewalls integrados, equilibrio de carga y configuración elástica de IPs externas según la demanda.

Google App Engine [GAE]

Modelo de plataforma sin servidores totalmente gestionada. Permite autoescalado inmediato, versionado ágil de código y división programada de tráfico web sin intervención en los sistemas operativos.

| Ingesta y Streaming: Pub/Sub vs. Dataflow

Google Cloud Pub/Sub

Servicio global de ingesta de eventos asíncrona. Actúa como intermediario de mensajería escalable con fiabilidad integrada, soporte flexible de suscripción (Push/Pull) y control de flujo integrado.

Google Cloud Dataflow

Servicio unificado de procesamiento analítico en tiempo real y por lotes (basado en Apache Beam). Aplica autoescalado inteligente y minimiza los costes reduciendo latencias.

| Datos en GCP: Cloud SQL vs. BigQuery

Google Cloud SQL

Servicio de base de datos relacional totalmente gestionado para MySQL, PostgreSQL y SQL Server. Proporciona parches, copias de seguridad automáticas y alta disponibilidad para entornos corporativos.

Google BigQuery

Almacén de datos empresariales (DWH) sin servidores altamente escalable. Su motor de consultas de rendimiento masivo analiza terabytes de datos no indexados en segundos utilizando SQL.

| El Increíble Rendimiento de BigQuery

24.7s

Tiempo de Consulta El transcurrido

Wikipedia 100B Benchmark

En pruebas estandarizadas sobre un conjunto de datos público masivo de Wikipedia que contiene más de 100.000 millones de filas sin indexar (~4.06 terabytes procesados), BigQuery ejecutó una búsqueda compleja con expresiones regulares en menos de 25 segundos.

El sistema se escala dinámicamente y distribuye la carga de trabajo entre miles de núcleos sin requerir ninguna intervención o pre-provisionamiento de hardware.

| Casos de Éxito en GCP Analytics

Disney Interactive

Con más de 500 juegos activos de la firma, la migración de un clúster tradicional de Hadoop con 1.000 núcleos hacia BigQuery redujo el tiempo de procesamiento de consultas complejas ad-hoc de 2.5 horas a menos de 5 minutos.

Spotify Technologies

Los científicos de datos de Spotify declararon de forma pública que BigQuery transformó de forma radical sus rutinas de investigación al permitirles procesar 2.200 millones de eventos brutos en menos de un minuto.

¡Excelente Trabajo!

Hemos completado con éxito el bloque final del curso de BigData.